

智慧老人醫院病患分流預測系統 — 提案計畫書

專案名稱：Elderly Hospital Patient Triage Prediction System (EHPTS) 版本：v1.0.0 | 狀態：提案階段 提案單位：奇美醫療財團法人奇美醫院 × 國立成功大學資訊工程學系 提案日期：2026 年 3 月

目錄

- 1. 專案摘要
- 2. 背景與問題描述
- 3. 專案目標
- 4. 現行分類規則與標籤設計
- 5. 資料概況與探索性分析
- 6. 分析方法論
- 7. 初步分析成果
- 8. 系統架構設計
- 9. 專案時程規劃
- 10. 預算規劃
- 11. 預期效益與風險評估
- 12. 結論與展望
- 13. 參考資料

專案摘要

本計畫旨在建構一套**智慧型病患分流預測系統**，利用機器學習技術與統計分析方法，將醫院住院病患依照臨床特徵自動分類為「**一般醫院**」或「**老人醫院**」兩大群體。目前醫師已依據臨床經驗，制定一套基於 *入院年齡*、*住院天數*、*加護病房使用天數* 等指標的規則，將超過十萬筆病患資料完成初步標記。

核心價值：透過深度群體特徵分析，找出兩群體間的**關鍵差異因子**，使未來的分類流程更加快速、精準，並降低醫療資源的錯配率。

本計畫分為三大階段：

- 1. **資料前處理與標籤建立**（已完成）
- 2. **群體特徵分析與關鍵因子挖掘**（進行中）
- 3. **預測模型建構與系統整合**（規劃中）

最終目標是部署一套可供護理站使用的**即時分流預測服務**，在病患入院登記時即自動給出分流建議，將人工判斷時間從分鐘級壓縮至秒級。

背景與問題描述

台灣高齡化趨勢

台灣已於 **2018 年** 進入高齡社會（65 歲以上人口超過 14%），預計 **2025 年** 邁入超高齡社會（超過 20%）。根據國家發展委員會的推估，至 **2030 年** 老年人口將達到約 559 萬人，佔總人口的 **24.1%**。

高齡化不僅是人口統計的數字變化，更是醫療資源配置模式的根本性轉型。

醫療資源分配的挑戰

隨著老年人口急速增長，現有醫療體系面臨以下挑戰：

- **病床資源緊張**：急性病床與慢性照護病床的需求比例失衡
- **分類效率低下**：目前依賴醫師人工判斷，耗時且一致性不足
- **成本持續攀升**：不適當的住院安排導致健保支出浪費
- 一般醫院群體平均健保記帳總額約 **165,302 元**
- 老人醫院群體平均健保記帳總額約 **76,667 元**
- 兩群體每案差距高達約 **88,635 元**

問題陳述

目前醫師已根據臨床規則將病患分為兩類，但此分類方式存在以下限制：

規則剛性	僅依據少數欄位（年齡、住院天數、加護病房天數），未考量其他潛在特徵
效率瓶頸	人工判斷耗時，無法即時處理大量入院案件
缺乏解釋性	未能充分理解兩群體間的深層特徵差異
自動化系統	目前尚無自動化分流系統，全仰賴人工流程

本計畫的定位

本計畫並非取代醫師的臨床判斷，而是在醫師既有規則的基礎上，透過資料科學方法：

1. **深入理解**兩群體的特徵差異
2. **量化驗證**現行規則的有效性
3. **發現**潛在的分流參考因子
4. **建構**輔助決策的自動化工具

專案目標

短期目標（3 個月內）

- ☒ 完成住院明細資料清洗與標籤建立
- ☒ 完成 42 個科別的分群交叉統計分析
- ☐ 完成連續型與類別型特徵的顯著性檢定
- ☐ 完成 Random Forest 特徵重要性排序

中期目標（6 個月內）

- ☐ 建構預測模型，達成分類準確率 $\geq 90\%$

- ☐ 開發分流預測 API 服務
- ☐ 完成前端儀表板原型設計

長期目標（12 個月內）

- ☐ 系統正式上線，完成與醫院 HIS 系統介接
- ☐ 累積運行數據，持續優化模型效能
- ☐ 擴展至多院區協作部署

現行分類規則與標籤設計

標籤定義

醫師團隊制定的分群標籤定義如下：

- `hospital_label = 0`：一般醫院患者（General Hospital）— 需要急重症或高強度醫療服務
- `hospital_label = 1`：老人醫院患者（Elderly Hospital）— 適合標準化、穩定性照護服務

分類規則流程

分類邏輯依照**優先順序**判定，整體決策流程如下：

[Mermaid flowchart — 請參閱 HTML 版本以檢視互動式圖表]

規則核心程式碼

以下為建立分群標籤的關鍵 Python 函式片段：

```
def create_hospital_label(df: pd.DataFrame) -> pd.DataFrame:
    """
    Create hospital_label column.
    0 = General Hospital
    1 = Elderly Hospital

    Priority rules:
    P1: age < 50 -> force label 0
    P2: TwDRGs note 2-9 -> force label 0
    Otherwise: any condition met -> label 1
    """
    df["hospital_label"] = 0 # default: general hospital

    # Priority filters - force label 0
    age_lt_50 = (df["age"] >= 0) & (df["age"] < 50)
    twdrgs_sp = df["twdrgs_note"].apply(is_special_twdrgs)
    priority = age_lt_50 | twdrgs_sp

    # Condition filters - assign label 1 if any met
    c1 = df["length_of_stay"] <= 7 # LOS ≤ 7 days
    c2 = df["trial_plan"].notna() # trial plan exists
    c3 = df["icu_days"] <= 3 # ICU days ≤ 3
    any_cond = c1 | c2 | c3

    df.loc[~priority & any_cond, "hospital_label"] = 1
    return df
```

標籤分佈統計

兩種不同條件嚴格度下的標籤分佈對比：

任一條件成立版	6,117	42,460	48,577	87.41%
全部條件成立版	48,423	154	48,577	0.32%
正式分析版本	39,781	69,820	109,601	63.7%

注意： 條件嚴格度的選擇對分群結果有**極端影響**— 從 87.4% 到 0.3%，凸顯了閾值設計在醫療決策系統中的重要性。

資料概況與探索性分析

資料集基本資訊

本計畫使用近三年（2023-2025）的住院明細資料，基本統計如下：

總樣本數 \ (N\)	109,601		
Group 0（一般醫院）	39,781 筆 (36.3%)		
Group 1（老人醫院）	69,820 筆 (63.7%)		
連續型特徵數	30		
類別型特徵數	23		
涵蓋科別數	42		

兩群體基本特徵對比

以下表格呈現兩群體在核心臨床指標上的差異（金額單位：新台幣元）：

平均入院年齡	42.0 歲	67.9 歲	1.6x
平均住院天數	11.5 天	5.4 天	2.1x
平均 ICU 天數	2.62 天	0.12 天	21.8x
平均健保記帳總額	165,302	76,667	2.2x
平均診察費	9,703	3,926	2.5x
平均病房費	25,131	9,128	2.8x

科別分佈概況

全院 **42 個科別** 的分群標籤分佈呈現高度異質性。部分科別幾乎全數歸類為老人醫院群體，另一些科別則以一般醫院群體為主。以老人醫院佔比排序，前五大科別為：

- 1. 科別 **31** — 老人醫院比例最高，住院量約 5,000 筆
- 2. 科別 **40** — 老人醫院比例次高

- 3. 科別 **02** — 樣本量大且老人醫院佔比顯著
- 4. 科別 **03** — 全院樣本量最大（約 9,000 筆），老人醫院比例高
- 5. 科別 **04** — 老人醫院比例同樣突出

科別層級的差異分析顯示，**病患的出院科別**本身就是一個強力的分群特徵（Cramer's V= 0.383），具有中等以上的關聯強度。

群體特徵差異的數學定義

為嚴謹量化兩群體的差異程度，本計畫使用以下效應量指標：

連續型特徵 — Cohen's *d*（衡量兩組平均值差異的標準化指標）：

$$d = \frac{\bar{X}_1 - \bar{X}_0}{S_p}$$

其中 pooled standard deviation 的計算方式為：

$$S_p = \sqrt{\frac{(n_1 - 1) s_1^2 + (n_0 - 1) s_0^2}{n_1 + n_0 - 2}}$$

類別型特徵 — Cramer's *V*（衡量兩個類別變數間的關聯強度）：

$$V = \sqrt{\frac{\chi^2}{n \cdot (\min(r, c) - 1)}}$$

其中 r 和 c 分別為列聯表的行數和列數， χ^2 為卡方統計量， n 為總樣本數。

效應量判讀標準：

Cohen's <i>d</i>	0.2	0.5	0.8
Cramer's <i>V</i>	0.1	0.3	0.5

分析方法論

整體分析流程

本計畫採用**四階段遞進式分析**策略：

[Mermaid graph — 請參閱 HTML 版本以檢視互動式圖表]

各階段詳細步驟

階段一：資料前處理

- 1. **資料載入**：從醫院資訊系統匯出近三年住院明細原始資料
- 2. **欄位清洗**：
- 3. 將缺失值統一填補為 -1 標記
- 4. 數值型欄位以安全轉換函式處理
- 5. 字串型欄位去除前後空白
- 6. **標籤建立**：依照分類規則建立分群標籤
- 7. **資料品質驗證**：確認標籤分佈合理、無重複記錄

階段二：探索性分析 (EDA)

- 各欄位分佈視覺化 (直方圖、箱形圖)
- 科別交叉統計 (行內比例分析)
- 缺失值比例分析
- 異常值偵測 (IQR 法則)

階段三：統計檢定

針對兩群體進行雙重顯著性差異檢定：

連續型	Independent <i>t</i> -test	Mann-Whitney <i>U</i> -test	Cohen's <i>d</i>	$(\alpha = 0.05)$
類別型	Chi-squared test (χ^2)	—	Cramer's <i>V</i>	$(\alpha = 0.05)$

同時使用參數與無母數檢定，可確保在資料不符常態分佈假設時，結論仍然穩健。

階段四：機器學習建模

- **模型選擇**：Random Forest Classifier
- **目的**：量化各特徵對分群的重要性**排序**，而非單純追求預測準確率
- **超參數**：`n_estimators=100`、`max_depth=None`、`random_state=42`
- **交叉驗證**：5-fold Stratified Cross-Validation
- **評估指標**：`accuracy`、`precision`、`recall`、`F1-score`、`AUC-ROC`

技術堆疊

```
Language: Python 3.10+
Core Libraries:
- pandas >= 2.0      # data processing
- numpy >= 1.24       # numerical computation
- scikit-learn >= 1.3 # machine learning
- scipy >= 1.11       # statistical tests
- matplotlib >= 3.7   # static visualization
- seaborn >= 0.12     # statistical visualization
- openpyxl >= 3.1     # Excel I/O
IDE: Jupyter Notebook / VS Code
VCS: Git + GitHub
```

初步分析成果

顯著差異特徵摘要

經過完整統計檢定後，共篩選出 **3 個**連續型顯著差異特徵和 **5 個**類別型顯著差異特徵（以中等以上效應量為門檻）。

連續型特徵 (Cohen's *d*達中等以上)

1	入院年齡	-1.686	Large	<0.0001
---	------	--------	-------	---------

2	住院天數	0.513	Medium	< 0.0001
3	診察費	0.500	Medium	< 0.0001

入院年齡的效應量 $|d| = 1.686$ 遠超大效應門檻 (0.8) ，為兩群體間最具區辨力的連續型特徵。

類別型特徵 (Cramer's V達中等以上)

1	TwDRGs 案件特殊註記	0.476	< 0.0001
2	出院醫師代碼	0.438	< 0.0001
3	出院護理站	0.419	< 0.0001
4	出院科別代碼	0.383	< 0.0001
5	科別	0.338	< 0.0001

Random Forest 特徵重要性 Top 10

透過 Random Forest 模型量化各特徵的分群貢獻度：

1	入院年齡	0.5478	54.8%
2	加護病房天數	0.0461	4.6%
3	病患來源	0.0356	3.6%
4	出院護理站	0.0350	3.5%
5	病房費	0.0328	3.3%
6	診察費	0.0324	3.2%
7	TwDRGs 特殊註記	0.0280	2.8%
8	出院科別代碼	0.0253	2.5%
9	給別	0.0240	2.4%
10	住院天數	0.0238	2.4%

關鍵發現：入院年齡單一特徵的重要性高達 **54.78%**，是第二名（加護病房天數 4.61%）的 **11.9 倍**。這意味著年齡是決定病患歸屬的壓倒性因子，但同時也暗示現行規則可能**過度依賴年齡**，而忽略了其他具潛力的輔助特徵。

群體特徵總結

兩大群體的核心差異可歸納如下：

[Mermaid mindmap — 請參閱 HTML 版本以檢視互動式圖表]

系統架構設計

目標系統概念

本系統設計為一個**三層式架構**的即時分流預測服務：



預測 API 規格

系統對外提供的核心 API 端點設計如下：

```
{
  "endpoint": "POST /api/v1/predict",
  "description": "Patient triage prediction",
  "request_body": {
    "patient_id": "string",
    "age": "integer",
    "length_of_stay": "integer",
    "icu_days": "integer",
    "department_code": "string",
    "twdrg_note": "string"
  },
  "response": {
    "hospital_label": "0 | 1",
    "confidence": "float (0.0 ~ 1.0)",
    "top_factors": ["age", "length_of_stay", "icu_days"],
    "rule_based_result": "0 | 1",
    "model_based_result": "0 | 1"
  }
}
```

資料流程

系統的完整資料處理流程如下：

- 1. **入院登記**：護理站人員輸入病患基本資訊
- 2. **規則預篩**：先經過醫師制定的規則引擎篩選
- 3. **模型預測**：通過規則引擎後，交由 ML 模型進行信心度預測
- 4. **結果合併**：綜合規則結果與模型預測，產出最終分流建議
- 5. **結果展示**：在儀表板上顯示分流結果、信心度與主要影響因子

預測結果範例

以下為一筆模擬預測的 API 呼叫範例：


```
# Call the triage prediction API
curl -X POST https://ehpts.example.com/api/v1/predict \
  -H "Content-Type: application/json" \
  -d '{
    "patient_id": "P20260301-001",
    "age": 72,
    "length_of_stay": 5,
    "icu_days": 0,
    "department_code": "03",
    "twdrng_note": "C"
  }'

# Expected response:
# {
#   "hospital_label": 1,
#   "confidence": 0.94,
#   "top_factors": ["age", "length_of_stay", "twdrng_note"]
# }
```

專案時程規劃

甘特圖

[Mermaid gantt — 請參閱 HTML 版本以檢視互動式圖表]

里程碑摘要

M1 — 資料就緒	2025/10/31	清洗後資料集與標籤欄位	資料完整率 $\geq 95\%$
M2 — 分析完成	2026/01/31	群體特徵報告與統計結果	報告涵蓋所有 53 個特徵
M3 — 模型就緒	2026/03/31	訓練好的 RF 模型與評估報告	F1-score ≥ 0.90
M4 — 系統上線	2026/08/01	完整分流預測系統	預測延遲 ≤ 200 ms

預算規劃

總預算概估

所有金額單位為**新台幣（NTD）**：

人力成本	資料科學家	80,000/月	12 個月	960,000
	後端工程師	70,000/月	6 個月	420,000
	前端工程師	65,000/月	4 個月	260,000
計算資源	GPU 伺服器租用（訓練）	15,000/月	6 個月	90,000

	雲端部署 (AWS / GCP)	10,000/月	12 個月	120,000
軟體授權	資料視覺化工具	30,000/年	1 年	30,000
雜支	會議、差旅、耗材	—	—	50,000
			總計	1,930,000

成本效益分析

以現行資料規模估算，若系統每月可協助正確分流 **500 例** 住院案件，每案平均節省健保差額的 **10%**（保守估計），則年度節省金額為：

$$\text{Annual Saving} = 500 \times 12 \times 88,635 \times 0.1 \approx 53,181,000 \text{ NTD}$$

投資報酬率估算：

$$\text{ROI} = \frac{53,181,000 - 1,930,000}{1,930,000} \times 100\% \approx 2,655\%$$

即使實際節省比例僅達估算的 **十分之一**，投資報酬率仍超過 200%，顯示本計畫具有極高的經濟效益潛力。

預期效益與風險評估

預期效益

- ☒ **分類速度提升**：從人工判斷（分鐘級）提升至系統預測（秒級），效率提升超過 100 倍
- ☒ **一致性保障**：消除因醫師個人判斷差異導致的分類不一致問題
- ☒ **特徵洞察**：揭示入院年齡、加護病房使用率、診察費等關鍵分流因子
- ☐ **成本優化**：透過精準分流降低健保支出浪費（待驗證）
- ☐ **擴展性**：模型可推廣至其他合作醫療機構（待驗證）
- ☐ **即時監控**：建立分流品質儀表板，持續追蹤系統表現（規劃中）

風險評估矩陣

風險項目	可能性 (Likelihood)	嚴重性 (Impact)	緩解策略 (Mitigation)
資料品質不佳導致模型偏差	Medium	High	建立自動化資料清洗管線，設置品質監控告警
模型過擬合 (Overfitting)	Medium	Medium	採用 Stratified k-fold 交叉驗證 + L2 正則化
醫護人員對系統接受度低	Low	High	提供 SHAP 可解釋性報告，讓醫師理解模型邏輯
法規合規風險 (醫療資料保護)	Low	High	資料去識別化處理，諮詢醫療法律顧問
系統效能瓶頸 (高峰時段)	Low	Medium	導入 Redis 快取機制 + 負載均衡架構

風險象限圖



結論與展望

結論

本提案計畫書完整描述了**智慧老人醫院病患分流預測系統**的建構動機、方法論、初步成果與實施規劃。核心發現包括：

1. **入院年齡**是兩群體間最具區辨力的單一特徵 (Cohen's $d = -1.686$)，RF 重要性 54.78%)
2. 兩群體在**醫療費用** (每案差距約 88,635 元) 和 **ICU 使用率** (差距 21.8 倍) 上存在巨大差異
3. 現行規則有效但存在優化空間，**TwDRGs 特殊註記** (Cramer's $V = 0.476$)、**出院科別**等類別特徵可作為輔助分流依據

未來展望

本計畫完成後，預計可延伸至以下方向：

1. **Deep Learning 強化**：以 *Neural Network* (如 `TabNet`、`FT-Transformer`) 捕捉更複雜的非線性特徵交互
2. **多院區聯邦學習**：在保護病患隱私的前提下，整合多間醫院資料進行 `Federated Learning` 聯合建模
3. **即時串流預測**：結合 `Apache Kafka` + `Ray Serve` 實現即時入院分分管線
4. **LLM 輔助解釋**：利用大型語言模型自動產生分流決策的自然語言解釋報告

技術展望路線圖

[Mermaid timeline — 請參閱 HTML 版本以檢視互動式圖表]

資料驅動的醫療決策，不是取代醫師的直覺，而是為直覺提供堅實的證據支撐。

參考資料

1. 國家發展委員會 — 中華民國人口推估 (2024 至 2070 年)
2. 衛生福利部中央健康保險署 — TwDRGs 支付制度說明
3. scikit-learn — RandomForestClassifier API Reference
4. SciPy — Statistical Functions Reference
5. FastAPI — Modern Python Web Framework
6. Mermaid — JavaScript-based Diagramming Tool
7. Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences* (2nd ed.). Lawrence Erlbaum Associates.
8. Cramer, H. (1946). *Mathematical Methods of Statistics*. Princeton University Press.
9. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. DOI: 10.1023/A:1010933404324

文件結尾 本文件以 Markdown 撰寫，可透過 Pandoc 或 Python-Markdown 渲染為 PDF 與 HTML。本文件核心創意與資料分析由作者完成，AI 工具用於輔助文字編排與語法檢查。最後更新：2026 年 3 月